

Теоретический анализ сходимости Proximal GaLore Adam

1 Базовые предположения (Assumptions)

Для анализа сходимости алгоритма в невыпуклом случае мы опираемся на следующие стандартные условия:

Условие 1 (L -гладкость). Функция потерь $f(w)$ дифференцируема и ее градиент является L -липшицевым:

$$\|\nabla f(w) - \nabla f(w')\| \leq L \|w - w'\|, \quad \forall w, w' \quad (1)$$

Условие 2 (Ограниченность снизу). Существует глобальный минимум f^* :

$$f(w) \geq f^* > -\infty, \quad \forall w \quad (2)$$

Условие 3 (Ограниченная дисперсия батчей). Стохастический градиент g_t является несмещенной оценкой с ограниченной дисперсией:

$$\mathbb{E}[g_t] = \nabla f(w_t), \quad \mathbb{E}[\|g_t - \nabla f(w_t)\|^2] \leq \sigma^2 \quad (3)$$

Условие 4 (Ограниченность градиентов). Норма стохастического градиента строго ограничена: $\|g_t\| \leq G$.

2 Главная Теорема

Определим градиент после SVT-проекции как $\tilde{g}_t = g_t + \epsilon_t$, где ϵ_t — матрица ошибки отсечения. Матрицу предобуславливания Adam (включая проекцию) обозначим как H_t , при этом $\lambda(H_t) \in [c_{min}, c_{max}]$.

Теорема 1 (Сходимость Proximal GaLore Adam). Пусть выполнены Условия 1–4. Если оптимизатор использует шаг $\eta_t = \frac{\eta}{\sqrt{t}}$ и расписание порога SVT $\lambda_t = \frac{c}{t^2}$, то после T итераций выполняется:

$$\min_{t \in [1, T]} \mathbb{E} [\|\nabla f(w_t)\|^2] \leq \mathcal{O} \left(\frac{f(w_1) - f^*}{\sqrt{T}} \right) + \mathcal{O} \left(\frac{\sigma^2}{\sqrt{T}} \right) + \mathcal{O} \left(\frac{C_\epsilon}{T} \right) \quad (4)$$

где C_ϵ — константа, ограничивающая суммарную ошибку проксимального оператора.

3 Доказательство

Доказательство. Шаг алгоритма задается уравнением: $w_{t+1} = w_t - \eta_t H_t \tilde{g}_t$.

Шаг 1: Лемма об убывании (Descent Lemma)

Используя Условие 1, запишем фундаментальное неравенство:

$$f(w_{t+1}) \leq f(w_t) + \langle \nabla f(w_t), w_{t+1} - w_t \rangle + \frac{L}{2} \|w_{t+1} - w_t\|^2 \quad (5)$$

Подставляя шаг обновления, получаем:

$$f(w_{t+1}) \leq f(w_t) - \eta_t \langle \nabla f(w_t), H_t \tilde{g}_t \rangle + \frac{L\eta_t^2}{2} \|H_t \tilde{g}_t\|^2 \quad (6)$$

Зафиксируем w_t и возьмем условное математическое ожидание $\mathbb{E}_t[\cdot]$ по случайности мини-батча на шаге t . Значения $f(w_t)$ и $\nabla f(w_t)$ являются детерминированными при условии известной истории до шага t , поэтому мы можем вынести их из-под знака ожидания:

$$\mathbb{E}_t[f(w_{t+1})] \leq f(w_t) - \eta_t \langle \nabla f(w_t), H_t \mathbb{E}_t[\tilde{g}_t] \rangle + \frac{L\eta_t^2}{2} \mathbb{E}_t[\|H_t \tilde{g}_t\|^2] \quad (7)$$

Поскольку $\tilde{g}_t = g_t + \epsilon_t$, а стохастический градиент является несмещенной оценкой (Условие 3), мы имеем $\mathbb{E}_t[g_t] = \nabla f(w_t)$. Отсюда следует, что ожидание возмущенного градиента равно $\mathbb{E}_t[\tilde{g}_t] = \nabla f(w_t) + \mathbb{E}_t[\epsilon_t]$.

Шаг 2: Изоляция ошибки SVT-оператора

Рассмотрим линейный член из уравнения (6). Подставив ожидание, имеем:

$$\mathbb{E}_t[\langle \nabla f(w_t), H_t \tilde{g}_t \rangle] = \langle \nabla f(w_t), H_t \nabla f(w_t) \rangle + \mathbb{E}_t[\langle \nabla f(w_t), H_t \epsilon_t \rangle] \quad (8)$$

Так как минимальное собственное значение матрицы предобуславливания H_t равно c_{min} , первое слагаемое строго ограничено снизу:

$$\langle \nabla f(w_t), H_t \nabla f(w_t) \rangle \geq c_{min} \|\nabla f(w_t)\|^2 \quad (9)$$

Для оценки второго слагаемого применим неравенство Юнга $\langle a, b \rangle \geq -\frac{\alpha}{2} \|a\|^2 - \frac{1}{2\alpha} \|b\|^2$. Выбрав параметр $\alpha = c_{min}$, положим $a = \nabla f(w_t)$ и $b = H_t \epsilon_t$:

$$\mathbb{E}_t[\langle \nabla f(w_t), H_t \epsilon_t \rangle] \geq -\frac{c_{min}}{2} \|\nabla f(w_t)\|^2 - \frac{1}{2c_{min}} \mathbb{E}_t[\|H_t \epsilon_t\|^2] \quad (10)$$

Учитывая свойство операторной нормы $\|H_t \epsilon_t\|^2 \leq c_{max}^2 \|\epsilon_t\|^2$ и объединяя оценки, получаем ограничение для линейного члена:

$$\mathbb{E}_t[\langle \nabla f(w_t), H_t \tilde{g}_t \rangle] \geq \frac{c_{min}}{2} \|\nabla f(w_t)\|^2 - \frac{c_{max}^2}{2c_{min}} \mathbb{E}_t[\|\epsilon_t\|^2] \quad (11)$$

Шаг 3: Ограничение квадратичного штрафа (Variance Bound)

Теперь оценим норму полного шага $\|H_t \tilde{g}_t\|^2$. Используя свойство $\|H_t \tilde{g}_t\|^2 \leq c_{max}^2 \|\tilde{g}_t\|^2$, представим возмущенный стохастический градиент как сумму трех компонент: $\tilde{g}_t = \nabla f(w_t) + (g_t - \nabla f(w_t)) + \epsilon_t$.

Применяя неравенство $\|a + b + c\|^2 \leq 3\|a\|^2 + 3\|b\|^2 + 3\|c\|^2$, получаем:

$$\|\tilde{g}_t\|^2 \leq 3\|\nabla f(w_t)\|^2 + 3\|g_t - \nabla f(w_t)\|^2 + 3\|\epsilon_t\|^2 \quad (12)$$

Беря математическое ожидание $\mathbb{E}_t[\cdot]$ и используя Условие 3 для ограничения дисперсии ($\mathbb{E}_t[\|g_t - \nabla f(w_t)\|^2] \leq \sigma^2$), приходим к следующей оценке:

$$\mathbb{E}_t[\|H_t \tilde{g}_t\|^2] \leq 3c_{max}^2 \left(\|\nabla f(w_t)\|^2 + \sigma^2 + \mathbb{E}_t[\|\epsilon_t\|^2] \right) \quad (13)$$

Шаг 4: Сборка и телескопическая сумма

Подставим (11) и (12) обратно в лемму об убывании и сгруппируем коэффициенты перед квадратом нормы градиента:

$$\begin{aligned}\mathbb{E}_t[f(w_{t+1})] &\leq f(w_t) - \eta_t \left(\frac{c_{min}}{2} - \frac{3L\eta_t c_{max}^2}{2} \right) \|\nabla f(w_t)\|^2 \\ &\quad + \frac{3L\eta_t^2 c_{max}^2}{2} \sigma^2 \\ &\quad + \eta_t \left(\frac{c_{max}^2}{2c_{min}} + \frac{3L\eta_t c_{max}^2}{2} \right) \mathbb{E}_t[\|\epsilon_t\|^2]\end{aligned}\tag{14}$$

Чтобы гарантировать, что коэффициент при $\|\nabla f(w_t)\|^2$ строго положителен, наложим условие на величину шага η_t . Потребуем, чтобы $\frac{3L\eta_t c_{max}^2}{2} \leq \frac{c_{min}}{4}$, что влечет $\eta_t \leq \frac{c_{min}}{6Lc_{max}^2}$. При таком выборе шага коэффициент перед градиентом ограничен снизу константой $\frac{c_{min}}{4}$.

Перенесем градиент в левую часть и переобозначив константу перед ошибкой как C_1 , получим:

$$\frac{\eta_t c_{min}}{4} \|\nabla f(w_t)\|^2 \leq f(w_t) - \mathbb{E}_t[f(w_{t+1})] + \frac{3L\eta_t^2 c_{max}^2}{2} \sigma^2 + \eta_t C_1 \mathbb{E}_t[\|\epsilon_t\|^2]\tag{15}$$

Беря полное математическое ожидание $\mathbb{E}[\cdot]$ (по всем шагам алгоритма), суммируя неравенство от $t = 1$ до T и деля на сумму $\sum_{t=1}^T \eta_t$, мы приходим к финальной телескопической оценке:

$$\frac{1}{T} \sum_{t=1}^T \mathbb{E}[\|\nabla f(w_t)\|^2] \leq \mathcal{O}\left(\frac{f(w_1) - f^*}{\sqrt{T}}\right) + \mathcal{O}\left(\frac{\sigma^2}{\sqrt{T}}\right) + \mathcal{O}\left(\frac{1}{T} \sum_{t=1}^T \mathbb{E}[\|\epsilon_t\|^2]\right)\tag{16}$$

Так как расписание порога задано как $\lambda_t = \frac{c}{t^2}$, квадратичная ошибка во Фробениусовой норме ограничена $\mathbb{E}[\|\epsilon_t\|^2] \leq d \cdot \frac{c^2}{t^4}$. Сумма ряда $\sum_{t=1}^T \frac{1}{t^4}$ сходится к константе. Следовательно, влияние ошибки SVT-оператора убывает со скоростью $\mathcal{O}(1/T)$, что завершает доказательство. $\square$