

Proximal GaLore: Динамическая адаптация ранга градиента через SVT

Виноградов Н. А., Агафонкин Е. Д., Гжибовский А. С.
МФТИ, Проект по курсу оптимизации, группа Б05-421

1. Введение и Мотивация

Обучение глубоких нейронных сетей требует значительных вычислительных ресурсов. Одним из главных узких мест является потребление памяти оптимизатором (хранение моментов первого и второго порядка, как в AdamW).

Оригинальный метод GaLore: Предлагает проекцию градиентов в низкоранговое подпространство с использованием SVD. Это позволяет существенно сократить размер состояний оптимизатора.

- Однако GaLore использует **жестко фиксированный ранг** r через Truncated SVD.

- Проблема:** Разные слои сети и разные стадии обучения требуют разной информационной емкости. Фиксированный ранг приводит либо к избыточному потреблению памяти, либо к деградации сходимости.

2. Метод: Proximal GaLore

Мы предлагаем устранить необходимость ручного подбора ранга, заменив Truncated SVD на проксимальный оператор ядерной нормы — **Singular Value Thresholding (SVT)**.

Формула обновления спектра:

$$SVT_{\lambda}(\Sigma) = \text{diag}(\max(\sigma_i - \lambda, 0))$$

Алгоритм на каждом K -ом шаге:

- Получение градиента G_t .
- Вычисление SVD разложения: $U, \Sigma, V^T = SVD(G_t)$.
- Применение порогового значения λ к сингулярным числам: $\tilde{\Sigma} = SVT_{\lambda}(\Sigma)$.
- Формирование адаптивных матриц проекции P_t .
- Шаг проекции состояния и обновления весов оптимизатором AdamW.

Главное преимущество: Ранг матрицы градиента (*effective rank*) адаптируется динамически. Неинформативные компоненты градиента зачисляются автоматически.

3. Эксперименты и Результаты

Метод был имплементирован и протестирован на задачах классификации изображений. Мы провели серию экспериментов с моделями MLP и сверточными сетями (CNN) на датасетах MNIST и FashionMNIST.


Базовое сравнение точности и памяти

Показатели валидационной точности на датасете MNIST (CNN-архитектура):

Оптимизатор	Точность	VRAM оптимизатора
AdamW (baseline)	99.19%	3.22 MB (100%)
GaLore ($r = 16$)	98.94%	0.38 MB ($\approx 12\%$)
Proximal GaLore	98.95%	0.36 MB ($\approx 11\%$)


Эксперимент А: Trade-off между точностью и памятью

Сравнение методов показало, что Proximal GaLore способен достигать точности, сопоставимой с GaLore, при этом в некоторых режимах эффективнее утилизируя подпространство градиентов (ниже потребление VRAM при той же точности) или достигая более высокой точности за счет динамически расширяемого ранга.



Эксперимент В: Финальная точность в зависимости от модели


На обеих архитектурах (MLP и CNN) мы наблюдали, что Proximal GaLore демонстрирует устойчивую сходимость, обходя по стабильности некоторые режимы фиксированного ранга GaLore, особенно на датасете FashionMNIST.



4. Вычислительная Сложность

В отличие от жесткого Truncated SVD, применение SVT требует вычисления более полного разложения для корректного порогового отсечения, что создает компромисс:

- Вычислительное время:** Увеличивается этап SVD-разложения (раз в K шагов).
- Снижение памяти:** Динамический ранг позволяет экономить память состояний в периоды "сглаживания" ландшафта лосса, когда градиент становится малоразмерным.



5. Основные Выводы

- Использование регуляризации ядерной нормой позволяет **адаптивно выбирать эффективную размерность подпространства** градиента в процессе обучения.
- Proximal GaLore демонстрирует **лучший баланс (trade-off)** между качеством сходимости финальной модели и занимаемой памятью по сравнению со статичным подходом.
- Наш подход избавляет исследователя от необходимости подбора параметра r для каждого слоя, что значительно упрощает настройку под новые, сложные архитектуры.

6. Ссылки

- GaLore:** Zhao, J., et al. (2024). *GaLore: Memory-Efficient LLM Training by Gradient Low-Rank Projection*. arXiv:2403.03507.
- Сингулярное отсечение:** Cai, J. F., et al. (2010). *A singular value thresholding algorithm for matrix completion*. SIAM Journal on optimization.
- Код проекта: github.com/.../galore