

Proximal GaLore: Динамическая адаптация ранга градиента через SVT

Виноградов Н. А., Агафонкин Е. Д., Гжибовский А. С.
МФТИ, Проект по курсу оптимизации, группа Б05-421

1. Введение и Мотивация

Обучение глубоких нейронных сетей требует значительных вычислительных ресурсов. Одним из главных узких мест является потребление памяти оптимизатором (хранение моментов первого и второго порядка, как в AdamW).

Оригинальный метод GaLore: Предлагает проекцию градиентов в низкоранговое подпространство с использованием SVD. Это позволяет существенно сократить размер состояний оптимизатора.

- Однако GaLore использует **жестко фиксированный ранг** r через Truncated SVD.
- Проблема:** Разные слои сети и разные стадии обучения требуют разной информационной емкости. Фиксированный ранг приводит либо к избыточному потреблению памяти, либо к деградации сходимости.

2. Метод: Proximal GaLore

Мы предлагаем устранить необходимость подбора фиксированного ранга r , заменив жесткое отсечение (Truncated SVD) на мягкое — проксимальный оператор ядерной нормы, или **Singular Value Thresholding (SVT)**. Это позволяет алгоритму автоматически определять "эффективную размерность" градиента.

Формула обновления спектра градиента:

$$\text{SVT}_\lambda(\Sigma) = \text{diag}(\max(\sigma_i - \lambda, 0))$$

Здесь λ — адаптивный порог. Если сингулярное число (т.е. вклад конкретного направления) меньше λ , оно обнуляется как неинформативный шум.

Алгоритм на каждом K -ом шаге:

- Снятие градиента:** Получение матрицы градиента G_t .
- Базовое разложение:** Вычисление SVD разложения: $U, \Sigma, V^T = \text{SVD}(G_t)$.
- Регуляризация (SVT):** Применение порогового значения λ к спектру. Получаем $\hat{\Sigma} = \text{SVT}_\lambda(\Sigma)$. Сингулярные числа $< \lambda$ исчезают.
- Адаптивная проекция:** Автоматическое формирование сжимающих матриц P_t на основе только оставшихся главных компонент.
- Шаг оптимизатора:** Обновление низкоразмерных состояний (моментов) в AdamW и обратная проекция весов.

Главное преимущество: Не нужно угадывать ранг. Эффективный ранг матрицы (*effective rank*) подстраивается под нужды конкретного слоя на каждой эпохе обучения. Неинформативный "хвост" градиента зануляется автоматически!

3. Эксперименты и Результаты

Метод был имплементирован и протестирован на задачах классификации изображений. Мы провели серию экспериментов с моделями MLP и сверточными сетями (CNN) на датасетах MNIST и FashionMNIST.


Базовое сравнение точности и памяти

Показатели валидационной точности на датасете MNIST (CNN-архитектура):

Оптимизатор	Точность	VRAM оптимизатора
AdamW (baseline)	99.19%	3.22 MB (100%)
GaLore ($r = 16$)	98.94%	0.38 MB ($\approx 12\%$)
Proximal GaLore	98.95%	0.36 MB ($\approx 11\%$)


Эксперимент А: Trade-off между точностью и памятью

Сравнение методов показало, что Proximal GaLore способен достигать точности, сопоставимой с GaLore, при этом в некоторых режимах эффективнее утилизируя подпространство градиентов (ниже потребление VRAM при той же точности) или достигая более высокой точности за счет динамически расширяемого ранга.



Эксперимент В: Обучение LLM (GPT-2)


Анализ Heatmap: Тепловая карта раскрывает механику алгоритма. SVT выделяет максимум информационной емкости (ранг >700) ранним MLP-слоям, агрессивно сжимая глубокие блоки. По шагам обучения эффективный ранг плавно повышается, грамотно подстраиваясь под сглаживание ландшафта лосса по мере сходимости модели. Это динамическое перераспределение полностью решает проблему жесткого ограничения классического GaLore.



4. Вычислительная Сложность

В отличие от жесткого Truncated SVD, применение SVT требует вычисления более полного разложения для корректного порогового отсечения, что создает компромисс:

- Вычислительное время:** Увеличивается этап SVD-разложения (раз в K шагов).
- Снижение памяти:** Динамический ранг позволяет экономить память состояний в периоды "сглаживания" ландшафта лосса, когда градиент становится малоразмерным.



5. Основные Выводы

- Использование регуляризации ядерной нормой позволяет **адаптивно выбирать эффективную размерность подпространства** градиента в процессе обучения.
- Proximal GaLore демонстрирует **лучший баланс (trade-off)** между качеством сходимости финальной модели и занимаемой памятью по сравнению со статичным подходом, однако работает чуть хуже.
- Наш подход избавляет исследователя от необходимости подбора гиперпараметра r для каждого слоя, однако требует подбора нового гиперпараметра λ - порога отсечения.

6. Ссылки

- GaLore:** Zhao, J., et al. (2024). *GaLore: Memory-Efficient LLM Training by Gradient Low-Rank Projection*. arXiv:2403.03507.
- Сингулярное отсечение:** Cai, J. F., et al. (2010). *A singular value thresholding algorithm for matrix completion*. SIAM Journal on optimization.
- Код проекта: <https://github.com/n3ke2710/galore/tree/main>