

# Proximal GaLore: Динамическая адаптация ранга градиента через SVT

Виноградов Н. А., Агафонкин Е. Д., Гжибовский А. С.  
МФТИ, Проект по курсу оптимизации, группа Б05-421

## 1. Введение и Мотивация

Обучение глубоких нейронных сетей требует значительных вычислительных ресурсов. Одним из главных узких мест является потребление памяти оптимизатором (хранение моментов первого и второго порядка, как в AdamW).

**Оригинальный метод GaLore:** Предлагает проекцию градиентов в низкоранговое подпространство с использованием SVD. Это позволяет существенно сократить размер состояний оптимизатора.

- Однако GaLore использует **жестко фиксированный ранг**  $r$  через Truncated SVD.

- Проблема:** Разные слои сети и разные стадии обучения требуют разной информационной емкости. Фиксированный ранг приводит либо к избыточному потреблению памяти, либо к деградации сходимости.

## 2. Метод: Proximal GaLore

Мы предлагаем устранить необходимость ручного подбора ранга, заменив Truncated SVD на проксимальный оператор ядерной нормы — **Singular Value Thresholding (SVT)**.

Формула обновления спектра:

$$SVT_{\lambda}(\Sigma) = \text{diag}(\max(\sigma_i - \lambda, 0))$$

**Алгоритм на каждом  $K$ -ом шаге:**

- Получение градиента  $G_t$ .
- Вычисление SVD разложения:  $U, \Sigma, V^T = SVD(G_t)$ .
- Применение порогового значения  $\lambda$  к сингулярным числам:  $\tilde{\Sigma} = SVT_{\lambda}(\Sigma)$ .
- Формирование адаптивных матриц проекции  $P_t$ .
- Шаг проекции состояния и обновления весов оптимизатором AdamW.

**Главное преимущество:** Ранг матрицы градиента (*effective rank*) адаптируется динамически. Неинформативные компоненты градиента заносятся автоматически.

## 3. Эксперименты и Результаты

Метод был имплементирован и протестирован на задачах классификации изображений. Мы провели серию экспериментов с моделями MLP и сверточными сетями (CNN) на датасетах MNIST и FashionMNIST.


**Базовое сравнение точности и памяти**

Показатели валидационной точности на датасете MNIST (CNN-архитектура):

| Оптимизатор            | Точность      | VRAM оптимизатора                          |
|------------------------|---------------|--------------------------------------------|
| AdamW (baseline)       | 99.19%        | 3.22 MB (100%)                             |
| GaLore ( $r = 16$ )    | 98.94%        | 0.38 MB ( $\approx 12\%$ )                 |
| <b>Proximal GaLore</b> | <b>98.95%</b> | <b>0.36 MB (<math>\approx 11\%</math>)</b> |


**Эксперимент А: Trade-off между точностью и памятью**

Сравнение методов показало, что Proximal GaLore способен достигать точности, сопоставимой с GaLore, при этом в некоторых режимах эффективнее утилизируя подпространство градиентов (ниже потребление VRAM при той же точности) или достигая более высокой точности за счет динамически расширяемого ранга.



**Эксперимент В: Обучение LLM (GPT-2)**


Анализ Heatmap: Тепловая карта раскрывает механику алгоритма. SVT выделяет максимум информационной емкости (ранг >700) ранним MLP-слоям, агрессивно сжимая глубокие блоки. По шагам обучения эффективный ранг плавно повышается, грамотно подстраиваясь под сглаживание ландшафта лосса по мере сходимости модели. Это динамическое перераспределение полностью решает проблему жесткого ограничения классического GaLore.



## 4. Вычислительная Сложность

В отличие от жесткого Truncated SVD, применение SVT требует вычисления более полного разложения для корректного порогового отсека, что создает компромисс:

- Вычислительное время:** Увеличивается этап SVD-разложения (раз в  $K$  шагов).
- Снижение памяти:** Динамический ранг позволяет экономить память состояний в периоды "сглаживания" ландшафта лосса, когда градиент становится малоразмерным.



## 5. Основные Выводы

- Использование регуляризации ядерной нормой позволяет **адаптивно выбирать эффективную размерность подпространства** градиента в процессе обучения.
- Proximal GaLore демонстрирует **лучший баланс (trade-off)** между качеством сходимости финальной модели и занимаемой памятью по сравнению со статичным подходом, однако работает чуть хуже.
- Наш подход избавляет исследователя от необходимости подбора гиперпараметра  $r$  для каждого слоя, однако требует подбора нового гиперпараметра  $\lambda$  - порога отсека.

## 6. Ссылки

- GaLore:** Zhao, J., et al. (2024). *GaLore: Memory-Efficient LLM Training by Gradient Low-Rank Projection*. arXiv:2403.03507.
- Сингулярное отсечение:** Cai, J. F., et al. (2010). *A singular value thresholding algorithm for matrix completion*. SIAM Journal on optimization.
- Код проекта: <https://github.com/n3ke2710/galore/tree/main>